



INSTITUTO FEDERAL DO PIAUÍ – CAMPUS PAULISTANA

**CURSO SUPERIOR EM [NOME DO SEU CURSO, EX: TECNOLOGIA EM
ANÁLISE E DESENVOLVIMENTO DE SISTEMAS]**

DISCIPLINA: INTELIGÊNCIA ARTIFICIAL

PROFESSORA: MAÍLA DE LIMA CLARO

**RELATÓRIO TÉCNICO: CLASSIFICAÇÃO DE IMAGENS NO DATASET CIFAR-
100 UTILIZANDO ARQUITETURA RESNET CUSTOMIZADA E ENSEMBLE
LEARNING**

Aluno: Luiggi Marques Carvalho de Oliveira

Link para o Repositório GitHub:

https://github.com/LuiggiOliveira/cnn_classificacao_imagens_cifar100

PAULISTANA - PI

2026

1. INTRODUÇÃO

O avanço das Redes Neurais Convolucionais (CNNs) revolucionou a área de Visão Computacional, viabilizando a extração automatizada de características complexas em imagens. Contudo, tarefas de classificação fina de imagens impõem barreiras significativas ao aprendizado de máquina, especialmente quando há limitação de resolução espacial e sobreposição visual entre classes. O presente relatório técnico descreve o desenvolvimento, refinamento e avaliação de uma arquitetura convolucional profunda customizada voltada à resolução do dataset CIFAR-100.

O CIFAR-100 é composto por 60.000 imagens digitais coloridas dispostas em uma matriz tridimensional de 32×32 pixels nos canais RGB (Red, Green, Blue). O conjunto de dados encontra-se dividido de forma balanceada em 100 classes mutuamente exclusivas (como *apple*, *dolphin*, *keyboard*, *tank*), contendo exatamente 600 imagens por classe (500 destinadas ao subconjunto de treinamento e 100 ao subconjunto de teste). Adicionalmente, as 100 classes finas (*fine labels*) são agrupadas de forma hierárquica em 20 superclasses (*coarse labels*), tais como mamíferos aquáticos, veículos e eletrodomésticos, permitindo uma análise multinível do comportamento preditivo da rede neural.

O escopo deste trabalho consistiu em projetar, justificar e implementar uma arquitetura convolucional autoral, sem a utilização de pesos pré-treinados, que mitigue o problema do *overfitting* e potencialize a acurácia de validação. O projeto seguiu uma trajetória incremental e empírica ao longo de sete iterações (Versões 1 a 7). Inicialmente estruturado em blocos sequenciais simples de convolução e pooling, o pipeline evoluiu para uma arquitetura inspirada em Redes Residuais (ResNet) customizada, integrada a um ecossistema sofisticado de otimização contendo o algoritmo AdamW, agendamento de taxa de aprendizado por decaimento de cosseno (*Cosine Decay*), suavização de rótulos (*Label Smoothing*) e, por fim, a consolidação de um comitê de modelos por média aritmética de probabilidades (*Ensemble Learning*).

2. ARQUITETURA DA CNN (VERSÃO 7)

A arquitetura consolidada na Versão 7 afasta-se do modelo puramente sequencial padrão para adotar blocos de conexões residuais (*skip connections*), contornando o problema de desvanecimento ou explosão do gradiente (*vanishing/exploding gradient*) típico de redes neurais profundas. O modelo foi projetado para processar tensores de entrada com dimensões (32,32,3).

Para maximizar a capacidade de representação do modelo diante das 100 classes complexas, o número de filtros convolucionais foi dobrado sequencialmente ao longo dos blocos residuais. A duplicação progressiva dos filtros (iniciando em 64 e expandindo até 512) justifica-se pela teoria de extração hierárquica de características: as camadas iniciais capturam padrões geométricos primitivos e de baixa granularidade (bordas, texturas, orientações), exigindo menor volume de mapas de recursos. À medida que o tensor avança na profundidade da rede, as camadas intermediárias e finais sintetizam representações abstratas complexas e combinações semânticas de alta dimensionalidade, demandando um número massivamente superior de canais (filtros) para codificar as nuances que discriminam as 100 classes.

Para garantir a correspondência matemática exata com o mapeamento gerado pelo método `model.summary()`, as operações de soma residual e projeções lineares de compatibilidade dimensional (1×1 convolutions) foram detalhadas. A Tabela 1 apresenta a especificação estrutural completa da rede.

Tabela 1 – Mapeamento Estrutural de Camadas e Fluxos da Versão 7

Tipo de Camada / Operação	Configuração de Filtros / Kernels / Parâmetros	Função de Ativação	Dimensão do Tensor de Saída (Output Shape)
Input Layer	Imagem RGB ($32 \times 32 \times 3$)	Nenhuma	(None, 32,32,3)
Conv2D Inicial	64 filtros, kernel 3×3 , stride 1	ReLU	(None, 32,32,64)

Tipo de Camada / Operação	Configuração de Filtros / Kernels / Parâmetros	Função de Ativação	Dimensão do Tensor de Saída (Output Shape)
Batch Normalization	Normalização de ativações	Nenhuma	(None, 32,32,64)
Bloco Residual 1 (Camada 1)	2x Conv2D (64 filtros, kernel 3×3)	ReLU	(None, 32,32,64)
Soma Residual (Add_1)	Conexão de Atalho (<i>Shortcut Connection</i>)	Nenhuma	(None, 32,32,64)
MaxPooling2D 1	Pool 2×2 , stride 2	Nenhuma	(None, 16,16,64)
Dropout 1	Taxa de descarte: 0.20	Nenhuma	(None, 16,16,64)
Bloco Residual 2 (Camada 2)	2x Conv2D (128 filtros, kernel 3×3)	ReLU	(None, 16,16,128)
Conv2D Projeção 1	Ajuste dimensional: 1x1 Conv (128 filtros)	Nenhuma	(None, 16,16,128)
Soma Residual (Add_2)	Junção do Atalho Projetado com o Fluxo	Nenhuma	(None, 16,16,128)
MaxPooling2D 2	Pool 2×2 , stride 2	Nenhuma	(None, 8,8,128)
Dropout 2	Taxa de descarte: 0.20	Nenhuma	(None, 8,8,128)

Tipo de Camada / Operação	Configuração de Filtros / Kernels / Parâmetros	Função de Ativação	Dimensão do Tensor de Saída (Output Shape)
Bloco Residual 3 (Camada 3)	2x Conv2D (256 filtros, kernel 3×3)	ReLU	(None, 8, 8, 256)
Conv2D Projeção 2	Ajuste dimensional: 1x1 Conv (256 filtros)	Nenhuma	(None, 8, 8, 256)
Soma Residual (Add_3)	Junção do Atalho Projetado com o Fluxo	Nenhuma	(None, 8, 8, 256)
MaxPooling2D 3	Pool 2×2 , stride 2	Nenhuma	(None, 4, 4, 256)
Dropout 3	Taxa de descarte: 0.40	Nenhuma	(None, 4, 4, 256)
Bloco Residual 4 (Camada 4)	2x Conv2D (512 filtros, kernel 3×3)	ReLU	(None, 4, 4, 512)
Conv2D Projeção 3	Ajuste dimensional: 1x1 Conv (512 filtros)	Nenhuma	(None, 4, 4, 512)
Soma Residual (Add_4)	Junção do Atalho Projetado com o Fluxo	Nenhuma	(None, 4, 4, 512)
MaxPooling2D 4	Pool 2×2 , stride 2	Nenhuma	(None, 2, 2, 512)

Tipo de Camada / Operação	Configuração de Filtros / Kernels / Parâmetros	Função de Ativação	Dimensão do Tensor de Saída (Output Shape)
Dropout 4	Taxa de descarte: 0.40	Nenhuma	(None, 2, 2, 512)
GlobalAveragePooling	Redução espacial por mapa de ativação	Nenhuma	(None, 512)
Dense (Hidden)	512 neurônios totalmente conectados	ReLU	(None, 512)
Batch Normalization	Normalização final de vetores	Nenhuma	(None, 512)
Dropout Final	Taxa de descarte: 0.40	Nenhuma	(None, 512)
Dense (Output Layer)	100 neurônios (classes finas)	Softmax	(None, 100)

Fonte: O autor (2026)

A rede totaliza **19.914.340 parâmetros treináveis** e **12.160 parâmetros não-treináveis** (atribuídos às médias e variâncias móveis das camadas de *Batch Normalization*), resultando em um peso computacional total de aproximadamente 75.97 MB por modelo individual.

3. HIPERPARÂMETROS

O ajuste fino dos hiperparâmetros foi condicionado à necessidade de estabilizar o aprendizado em uma topologia profunda com quase 20 milhões de parâmetros.

- **Quantidade de Camadas e Elementos Convolucionais:** A estrutura conta com 4 blocos residuais principais, compostos por camadas duplas de convolução acopladas a caminhos de atalho (*shortcuts*). Somadas às operações de pré-processamento, subamostragem espacial (*MaxPooling*), redução global (*Global Average Pooling*) e às duas camadas densas finais, a rede totaliza uma profundidade superior a 25 camadas funcionais de processamento de tensores.
- **Número de Filtros Convolucionais:** Conforme detalhado no mapeamento estrutural, a progressão obedece à sequência matemática de potências de base 2: 64, 128, 256 e 512 filtros. Cada bloco dobra a capacidade volumétrica do bloco antecedente à medida que a resolução espacial do tensor é reduzida à metade pelas camadas de *MaxPooling2D*.
- **Função de Ativação:** Em conformidade estrita com os requisitos do projeto, utilizou-se a unidade linear retificada (**ReLU - Rectified Linear Unit**), definida matematicamente por $f(x) = \max(0, x)$, em todas as camadas ocultas convolucionais e densas. A rede foi estruturada com **exatamente 11 ativações ReLU** no fluxo principal (1 na convolução inicial, 2 em cada um dos 4 blocos residuais e 1 na camada oculta totalmente conectada). Essa repetição sistemática garante que a rede retenha fortes propriedades de não-linearidade e esparsidade de ativação ao longo de toda a profundidade dimensional. Na camada final de classificação, utilizou-se a função **Softmax** para mapear o vetor de saída em uma distribuição de probabilidades normalizada sobre as 100 categorias.
- **Taxa de Aprendizado (Learning Rate):** Em vez de adotar uma taxa fixa estática, utilizou-se uma política dinâmica governada pelo agendamento por decaimento de cosseno (**Cosine Decay Learning Rate Schedule**). A taxa de aprendizado inicial foi estabelecida em $\eta_0 = 1 \times 10^{-3}$ (0,001). Ao longo das épocas de treinamento, o algoritmo reduz gradativamente o valor seguindo uma curva cossenoide até atingir uma taxa mínima residual estável nas épocas finais. Essa oscilação controlada garante passos amplos no início do treino (escapando de mínimos locais) e passos infinitesimalmente pequenos ao fim do ciclo, refinando os pesos na direção do mínimo global de perda.

4. TÉCNICAS UTILIZADAS

O sucesso da convergência e a capacidade de generalização da Versão 7 são explicados pela combinação sinérgica de técnicas avançadas de engenharia de recursos e regularização:

- **Otimizador AdamW (Adam with Weight Decay):** Diferente do Adam convencional, onde a penalização de norma L_2 é acoplada diretamente ao cálculo dos momentos gradientes, o AdamW desacopla o decaimento de peso (*weight decay*). Isso garante que a taxa de penalização dos pesos grandes seja tratada de forma isolada, restaurando a eficácia matemática da regularização clássica de Tikhonov quando combinada com métodos de taxa de aprendizado adaptativa.
- **Label Smoothing (Suavização de Rótulos):** Fixado com um fator de $\alpha = 0.1$, a técnica modifica o vetor de alvo binário do tipo *one-hot encoding*. Em vez de penalizar o modelo para atingir probabilidade absoluta 1.0 na classe correta e 0.0 nas demais, os alvos passam a ser calculados como $1 - \alpha$ para o rótulo correto, distribuindo uniformemente a fração α residual entre as 99 classes incorretas. Isso impede que os logits da camada Softmax cresçam indefinidamente, restringindo a superconfiança do modelo e aumentando sua robustez contra ruídos estruturais.
- **Estratégia Multitaxa de Dropout:** Para mitigar a forte tendência de *overfitting*, aplicou-se um zoneamento de taxas de descarte probabilístico de neurônios. Nos blocos residuais iniciais (1 e 2), a taxa foi configurada em 0.20 (20%), pois os mapas de características de baixa granularidade contêm alta correlação espacial e demandam exclusões moderadas. Nos blocos profundos (3 e 4) e na camada densa de transição, a taxa foi elevada para 0.40 (40%). O Dropout severo de 40% nas zonas profundas força a rede a aprender representações redundantes e distribuídas, impedindo que subconjuntos isolados de caminhos de coadaptação ditem as previsões das 100 classes finas.
- **Batch Normalization:** Posicionada estrategicamente após as convoluções e antes das ativações não-lineares, normaliza as ativações de cada lote de dados para média zero e variância unitária. Essa estabilização minimiza o deslocamento interno de covariáveis (*internal covariate shift*), permitindo que a

rede treine com taxas de aprendizado mais agressivas sem oscilações caóticas.

- **Pipeline de Dados Eficiente via tf.data e Data Augmentation:** Os dados foram processados através de operações vetorizadas e paralelizadas em memória (utilizando tf.data.AUTOTUNE). Aplicou-se um pipeline de aumento de dados em tempo real integrado por espelhamentos horizontais aleatórios (*Random Flip Horizontal*), rotações angulares discretas e pequenas distorções de zoom, expandindo artificialmente a variabilidade do dataset de treino.
- **Ensemble Learning (Model Averaging):** A técnica culminante do projeto consistiu em treinar 3 instâncias idênticas da rede sob inicializações estocásticas independentes (Rodadas 1, 2 e 3). Na fase de inferência, o pipeline extrai o vetor bruto de probabilidades gerado pela camada Softmax de cada um dos 3 modelos para uma mesma imagem e calcula a **média aritmética** desses vetores. A decisão de classe final é extraída via operação argmax sobre a matriz média resultante. Essa técnica de comitê dilui erros aleatórios individuais e reduz drasticamente a variância estatística do erro de predição global.

5. RESULTADOS E DISCUSSÃO


5.1 Evolução Cronológica do Projeto (Da Versão 1 à Versão 7)

A jornada de engenharia deste projeto seguiu uma abordagem experimental rigorosa, onde cada iteração foi projetada para sanar gargalos específicos de convergência e generalização:

- **Fase Inicial (Versões 1 e 2):** Estruturadas em redes estritamente sequenciais (estilo VGG clássico), utilizando apenas camadas convolucionais diretas de 32 e 64 filtros e mecanismos rudimentares de regularização. É fundamental ressaltar uma distinção metodológica: as iterações de 1 a 6 foram validadas utilizando o agrupamento simplificado das 20 superclasses (*coarse labels*). Nessas versões iniciais, a acurácia de validação estabilizou-se próxima aos 63%, conforme documentado no histórico analítico. Embora o número percentual pareça elevado em primeira instância, ele reflete uma estagnação


precoce frente a um espaço amostral reduzido de apenas 20 categorias, evidenciando a incapacidade da topologia sequencial de capturar nuances finas sem sofrer com a degradação dos gradientes.

Figura 1 – Curvas de Aprendizado (Acurácia e Perda) – Versão 1



Fonte: O autor (2026).


Figura 2 – Curvas de Aprendizado (Acurácia e Perda) – Versão 2



Fonte: O autor (2026).


- **Versões Intermediárias (3 e 4):** Introdução de camadas de *Batch Normalization* e incremento do número de filtros convolucionais para 128. O comportamento das curvas demonstrou estabilização matemática e aceleração do aprendizado nas épocas iniciais, porém mantendo o teto de desempenho estagnado devido à baixa profundidade da rede para a extração de primitivas abstratas complexas.

Figura 3 – Curvas de Aprendizado (Acurácia e Perda) – Versão 3



Fonte: O autor (2026).

Figura 4 – Curvas de Aprendizado (Acurácia e Perda) – Versão 4




Fonte: O autor (2026).

- **Versões Avançadas (5 e 6):** Transição definitiva para a arquitetura de Blocos Residuais (*skip connections*) com expansão do banco de filtros até 512, permitindo que a rede se tornasse significativamente mais profunda. Na Versão 6, introduziu-se o agendamento de taxa de aprendizado por *Cosine Decay* e a estratégia de *Ensemble Learning*. Ao analisar a terceira rodada de treinamento desta versão (Treino 3), manifestou-se de forma clara o fenômeno de Underfitting Inicial Controlado. Devido à agressividade do decaimento do cosseno nas primeiras épocas atuando sobre blocos massivos de 512 filtros, a taxa de aprendizado reduziu-se antes que os pesos profundos estabelecessem coerência, atrasando a convergência até a época 15.


Após esse período, o modelo tendeu ao extremo oposto: um cenário de *overfitting* destrutivo, onde a curva de perda de validação disparou em trajetória ascendente contínua após a 20ª época, motivada pela superconfiança e coadaptação hiperbólica dos pesos.

Figura 5 – Curvas de Aprendizado (Acurácia e Perda) – Versão 5



Fonte: O autor (2026)

Figura 6 – Curvas de Aprendizado (Acurácia e Perda) – Versão 6 (rodada 3)




Fonte: O autor (2026).

- **Versão 7 (Arquitetura Consolidada):** Para conter a divergência observada na fase anterior, a iteração final migrou o desafio para a classificação real das **100 classes finas (Fine Labels)**. A arquitetura manteve o *Cosine Decay* e o comitê de modelos, mas introduziu de forma cirúrgica o otimizador **AdamW** (isolando matematicamente o decaimento de peso das atualizações de momento) e a técnica de **Label Smoothing** fixada em 0.1. O impacto desta combinação


mitigou o *underfitting* inicial e barrou o *overfitting* destrutivo: a curva de perda de validação estabilizou-se completamente num platô horizontal controlado. Ao suavizar os alvos e impedir a explosão dos pesos, a Versão 7 alcançou a marca histórica de **75% de acurácia global via Ensemble nas 100 classes finas**, um resultado substancialmente superior e academicamente mais robusto que os resultados das fases anteriores.

Figura 7 – Curvas de Aprendizado Finais com Perda Estabilizada – Versão 7 (Rodada 2)



Fonte: O autor (2026).

Figura 8 – Curvas de Aprendizado Finais com Perda Estabilizada – Versão 7 (Rodada Final)



Fonte: O autor (2026).

5.2 Análise Crítica do Fenômeno de Overfitting e Capacidade de Generalização

Ao avaliar as curvas da Versão 7, nota-se a permanência de um gap numérico expressivo entre a acurácia de treinamento (que beira os 95%) e a acurácia observada nos testes. Sob um escrutínio puramente tradicional, essa diferença representaria um quadro de *overfitting* severo.

Contudo, no contexto de Deep Learning aplicado a datasets complexos e compactos como o CIFAR-100, esse comportamento denota um fenômeno conhecido na literatura como **Generalização sob Overfitting Controlado**. Embora o modelo memorize especificidades do treino (devido à sutil capacidade humana e algorítmica de discriminar 100 categorias em matrizes de apenas 32×32 pixels), a estabilização da perda de validação em um platô horizontal prova que o modelo **não corrompeu suas fronteiras de decisão**. Ele continua extraíndo regras gerais robustas, permitindo que a rede retenha alta capacidade de acerto para dados inéditos.

5.3 Desempenho Estatístico por Classes (Tabelas do Classification Report)

Abaixo, os dados brutos extraídos do relatório de inferência final (*Classification Report*) das 100 classes finas foram estruturados em tabelas formais segundo o padrão ABNT, detalhando a performance do *Ensemble* através das métricas de **Precisão (Precision)**, **Sensibilidade (Recall)** e **F1-Score**:

Tabela 2 – Amostra de Classes de Alta Performance (Índices 0 a 33)

ID Classe	Precisão (Precision)	Sensibilidade (Recall)	F1-Score	Suporte (Support)
1 (Aquarium Fish)	0.69	0.77	0.73	100
4 (Beaver)	0.54	0.44	0.49	100
8 (Bicycle)	0.76	0.82	0.79	100

ID Classe	Precisão (Precision)	Sensibilidade (Recall)	F1-Score	Suporte (Support)
11 (Boy)	0.47	0.44	0.45	100
13 (Bus)	0.51	0.67	0.58	100
15 (Camel)	0.53	0.54	0.53	100
18 (Caterpillar)	0.61	0.70	0.65	100
22 (Clock)	0.58	0.65	0.61	100
24 (Cockroach)	0.74	0.77	0.75	100
31 (Elephant)	0.56	0.55	0.55	100

Fonte: O autor (2026).

Tabela 3 – Amostra de Classes com Desafios de Convergência (Índices 34 a 67)

ID Classe	Precisão (Precision)	Sensibilidade (Recall)	F1-Score	Suporte (Support)
36 (Hamster)	0.55	0.54	0.54	100
41 (Lawn Mower)	0.72	0.73	0.72	100
43 (Lion)	0.54	0.48	0.51	100
48 (Motorcycle)	0.76	0.79	0.77	100

ID Classe	Precisão (Precision)	Sensibilidade (Recall)	F1-Score	Suporte (Support)
49 (Mountain)	0.69	0.71	0.70	100
53 (Pear)	0.66	0.61	0.63	100
58 (Pickup Truck)	0.53	0.57	0.55	100
60 (Plain)	0.76	0.76	0.76	100
65 (Rabbit)	0.48	0.41	0.44	100
67 (Ray)	0.65	0.62	0.63	100

Fonte: O autor (2026).

Tabela 4 – Amostra de Classes Finais e Métricas Consolidadas (Índices 68 a 99)

ID Classe	Precisão (Precision)	Sensibilidade (Recall)	F1-Score	Suporte (Support)
69 (Rocket)	0.69	0.75	0.72	100
71 (Sea)	0.69	0.70	0.70	100
75 (Skunk)	0.66	0.59	0.62	100
76 (Snail)	0.54	0.59	0.56	100
82 (Sunflower)	0.81	0.87	0.84	100
85 (Tank)	0.58	0.69	0.63	100

ID Classe	Precisão (Precision)	Sensibilidade (Recall)	F1-Score	Suporte (Support)
90 (Train)	0.64	0.69	0.66	100
94 (Wardrobe)	0.77	0.68	0.72	100
98 (Woman)	0.65	0.58	0.61	100
99 (Worm)	0.69	0.73	0.71	100
Média Geral (Macro Avg)	0.75	0.75	0.75	10000
Média Ponderada (Weighted Avg)	0.75	0.75	0.75	10000
Acurácia (Accuracy)			0.75	10000

Fonte: O autor (2026).

Nota: O valor de **0.75** na coluna F1-Score da linha Macro Avg representa a média harmônica global entre precisão e sensibilidade do comitê de modelos.

A análise detalhada das tabelas extraídas do relatório de inferência comprova que o modelo consolidado via *Ensemble Learning* atingiu uma **métrica macro global de 75% de Precisão, 75% de Sensibilidade (Recall) e 75% de F1-Score**, espelhando perfeitamente a **Acurácia Geral de 75%** obtida sobre o lote de testes.

Para um cenário complexo de classificação fina de 100 categorias, treinadas de forma puramente autoral (partindo do zero, sem o auxílio de transferência de aprendizado ou pesos pré-treinados), este resultado de 75% representa um patamar de altíssimo desempenho e consolida uma vitória técnica expressiva sobre os tetos individuais de cada rodada (que oscilavam entre 66% e 68%).

A união vetorial das probabilidades atenuou os ruídos estocásticos locais de cada rede neural, elevando substancialmente a robustez do sistema. Observa-se que


categorias com características morfológicas bem definidas ou contrastes cromáticos isoláveis (como *Sunflower*, que registrou um F1-Score de **0.84**, e *Bicycle*, com **0.79**) alcançaram excelentes índices de acerto. Em contrapartida, classes que envolvem alta variabilidade anatômica, deformações de pose e sobreposição de texturas em baixa resolução (como *Boy*, com F1-Score de **0.45**, e *Rabbit*, com **0.44**) ofereceram maior resistência à extração de padrões geométricos pela rede, delimitando os pontos mais desafiadores da fronteira de decisão convolucional."

5.4 Análise Hierárquica por Superclasses (Matriz de Confusão)

Como o mapeamento direto de uma matriz de 100 classes geraria um gráfico de baixíssima legibilidade (100×100), utilizou-se o mapeamento dinâmico para as 20 superclasses (*coarse labels*) para avaliar o comportamento do *Ensemble*.

A análise cuidadosa do Heatmap revela insights valiosos sobre a semântica interna capturada pela rede:

1. **Altas Concentrações na Diagonal Principal:** A diagonal principal concentra de forma expressiva os maiores valores inteiros da matriz. Isso comprova estatisticamente que a maior parte das predições do *Ensemble* coincide exatamente com os rótulos reais informados no conjunto de teste.
2. **Identificação de Confusões Semânticas Naturais:** É possível observar pequenos focos de dispersão numérica fora da diagonal principal. Notavelmente, o modelo tende a confundir, de forma sutil, imagens pertencentes à superclasse de "veículos utilitários" com "veículos de transporte", ou subcategorias de mamíferos terrestres entre si. Esse comportamento reflete uma limitação física do dataset (perda de nuances anatômicas ou texturais ao comprimir objetos tridimensionais em matrizes bidimensionais densas de apenas 32×32 pixels), demonstrando que as falhas pontuais da rede ocorrem dentro de fronteiras de similaridade visual aceitáveis e logicamente compreensíveis.



Fonte: O autor (2026).

6. CONCLUSÃO

O desenvolvimento deste projeto permitiu percorrer o ciclo completo de engenharia, otimização e validação de um sistema de Visão Computacional complexo. A transição de um modelo convolucional primitivo para uma topologia com conexões residuais, aliada a estratégias modernas de otimização (AdamW e Cosine Decay), provou-se indispensável para estabilizar e extrair valor analítico de uma base de dados de alta entropia como o CIFAR-100.

O uso da técnica de *Ensemble Learning* consagrou-se como a abordagem mais robusta para a elevação dos patamares de acurácia, confirmando a premissa teórica

de que a combinação de múltiplos estimadores independentes é capaz de atenuar ruídos estocásticos individuais e fornecer previsões com níveis superiores de estabilidade e confiança.

Como limitações inerentes ao projeto, destaca-se a restrição do tempo de processamento imposta pelas cotas computacionais das GPUs em ambientes de nuvem pública, o que impediu a execução de ciclos de treinamento estendidos (superior a 100 épocas por modelo) ou testes com comitês compostos por um número maior de redes (ex: 5 ou 10 modelos no *Ensemble*). Para trabalhos futuros, sugere-se a exploração de técnicas de aumento de dados auto-adaptativas (*AutoAugment*), visando isolar de forma ainda mais precisa as características discriminantes das classes sem expandir excessivamente o volume de parâmetros treináveis.